

NVIDIA NIM 可用模型列表

查询时间：2026-05-29 | 总计 118 个模型 | API: <https://integrate.api.nvidia.com/v1/models>

一、Chat/Instruct 模型（适用于 cheat_simulation 实验）

共 58 个可用的对话/指令模型，按厂商分组。

DeepSeek（2 个）

模型 ID	说明
deepseek-ai/deepseek-v4-pro	DeepSeek V4 Pro，旗舰
deepseek-ai/deepseek-v4-flash	DeepSeek V4 Flash，快速版

Meta / Llama 系列（12 个）

模型 ID	说明
meta/llama-4-maverick-17b-128e-instruct	Llama 4 Maverick 17B
meta/llama-3.3-70b-instruct	Llama 3.3 70B
meta/llama-3.1-70b-instruct	Llama 3.1 70B
meta/llama-3.1-8b-instruct	Llama 3.1 8B
meta/llama-3.2-3b-instruct	Llama 3.2 3B
meta/llama-3.2-1b-instruct	Llama 3.2 1B
meta/llama2-70b	Llama 2 70B
meta/codellama-70b	CodeLlama 70B

Mistral AI（9 个）

模型 ID	说明
mistralai/mistral-large-3-675b-instruct-2512	Mistral Large 3 675B
mistralai/mistral-large-2-instruct	Mistral Large 2
mistralai/mistral-large	Mistral Large (原版)
mistralai/mistral-medium-3.5-128b	Mistral Medium 3.5 128B
mistralai/mistral-small-4-119b-2603	Mistral Small 4 119B
mistralai/ministral-14b-instruct-2512	Ministral 14B

模型 ID	说明
mistralai/mistral-nemotron	Mistral Nemotron
mistralai/mistral-7b-instruct-v0.3	Mistral 7B v0.3
mistralai/mixtral-8x22b-v0.1	Mixtral 8x22B
mistralai/mixtral-8x7b-instruct-v0.1	Mixtral 8x7B
mistralai/codestral-22b-instruct-v0.1	Codestral 22B

NVIDIA Nemotron 系列（13 个）

模型 ID	说明
nvidia/llama-3.1-nemotron-ultra-253b-v1	Nemotron Ultra 253B
nvidia/llama-3.1-nemotron-70b-instruct	Nemotron 70B
nvidia/llama-3.1-nemotron-51b-instruct	Nemotron 51B
nvidia/llama-3.3-nemotron-super-49b-v1.5	Nemotron Super 49B v1.5
nvidia/llama-3.3-nemotron-super-49b-v1	Nemotron Super 49B v1
nvidia/llama-3.1-nemotron-nano-8b-v1	Nemotron Nano 8B
nvidia/nemotron-4-340b-instruct	Nemotron 4 340B
nvidia/nemotron-3-super-120b-a12b	Nemotron 3 Super 120B
nvidia/nemotron-3-nano-30b-a3b	Nemotron 3 Nano 30B
nvidia/nemotron-nano-3-30b-a3b	Nemotron Nano 3 30B
nvidia/nvidia-nemotron-nano-9b-v2	Nemotron Nano 9B v2
nvidia/nemotron-mini-4b-instruct	Nemotron Mini 4B
nvidia/mistral-nemo-minitron-8b-8k-instruct	Mistral Nemo Minitron 8B

Google Gemma 系列（6 个）

模型 ID	说明
google/gemma-4-31b-it	Gemma 4 31B
google/gemma-3-12b-it	Gemma 3 12B
google/gemma-3-4b-it	Gemma 3 4B
google/gemma-3n-e4b-it	Gemma 3n E4B
google/gemma-3n-e2b-it	Gemma 3n E2B
google/gemma-2-2b-it	Gemma 2 2B

Qwen 系列（4 个）

模型 ID	说明
qwen/qwen3.5-397b-a17b	Qwen 3.5 397B
qwen/qwen3.5-122b-a10b	Qwen 3.5 122B
qwen/qwen3-coder-480b-a35b-instruct	Qwen 3 Coder 480B
qwen/qwen3-next-80b-a3b-instruct	Qwen 3 Next 80B

Microsoft Phi 系列（2 个）

模型 ID	说明
microsoft/phi-4-mini-instruct	Phi 4 Mini
microsoft/phi-3.5-moe-instruct	Phi 3.5 MoE

IBM Granite 系列（4 个）

模型 ID	说明
ibm/granite-3.0-8b-instruct	Granite 3.0 8B
ibm/granite-3.0-3b-a800m-instruct	Granite 3.0 3B
ibm/granite-34b-code-instruct	Granite 34B Code
ibm/granite-8b-code-instruct	Granite 8B Code

StepFun（2 个）

模型 ID	说明
stepfun-ai/step-3.7-flash	Step 3.7 Flash
stepfun-ai/step-3.5-flash	Step 3.5 Flash

OpenAI（2 个）

模型 ID	说明
openai/gpt-oss-120b	GPT-OSS 120B
openai/gpt-oss-20b	GPT-OSS 20B

其他厂商（8 个）

模型 ID	说明
minimaxai/minimax-m2.7	MiniMax M2.7 ← 当前使用

模型 ID	说明
moonshotai/kimi-k2.6	Kimi K2.6
01-ai/yi-large	Yi Large
z-ai/glm-5.1	GLM 5.1
abacusai/dracarys-llama-3.1-70b-instruct	Dracarys 70B
ai21labs/jamba-1.5-large-instruct	Jamba 1.5 Large
stockmark/stockmark-2-100b-instruct	Stockmark 2 100B
writer/palmyra-creative-122b	Palmyra Creative 122B
bytedance/seed-oss-36b-instruct	Seed OSS 36B
databricks/dbrx-instruct	DBRX
upstage/solar-10.7b-instruct	Solar 10.7B
zyphra/zamba2-7b-instruct	Zamba2 7B
nv-mistralai/mistral-nemo-12b-instruct	Mistral Nemo 12B
aisingapore/sea-lion-7b-instruct	SEA-LION 7B
sarvamai/sarvam-m	Sarvam M

二、不建议使用的模型（Embedding / 安全 / 视觉专用 / 其他）

共 60 个，这些模型不适合 chat_simulation 实验。

Embedding / Retriever 模型（13 个）

模型 ID	说明
baai/bge-m3	BGE M3 Embedding
nvidia/embed-qa-4	Embed QA 4
nvidia/llama-3.2-nv-embedqa-1b-v1	NV EmbedQA 1B
nvidia/nv-embedqa-e5-v5	NV EmbedQA E5 v5
nvidia/nv-embedqa-mistral-7b-v2	NV EmbedQA Mistral 7B
nvidia/nv-embed-v1	NV Embed v1
nvidia/llama-nemotron-embed-1b-v2	Llama Nemotron Embed 1B
nvidia/llama-nemotron-embed-vl-1b-v2	Llama Nemotron Embed VL 1B
nvidia/llama-3.2-nemoretriever-1b-vlm-embed-v1	Nemo Retriever VLM Embed

模型 ID	说明
nvidia/nemoretriever-parse	Nemo Retriever Parse
nvidia/nemotron-parse	Nemotron Parse
nvidia/nv-embedcode-7b-v1	NV EmbedCode 7B
snowflake/arctic-embed-l	Arctic Embed L

安全/Guard 模型（6 个）

模型 ID	说明
meta/llama-guard-4-12b	Llama Guard 4 12B
nvidia/llama-3.1-nemoguard-8b-content-safety	NemoGuard Content Safety
nvidia/llama-3.1-nemoguard-8b-topic-control	NemoGuard Topic Control
nvidia/llama-3.1-nemotron-safety-guard-8b-v3	Nemotron Safety Guard
nvidia/nemotron-3-content-safety	Nemotron 3 Content Safety
nvidia/nemotron-content-safety-reasoning-4b	Nemotron Safety Reasoning 4B

视觉/多模态专用模型（6 个）

模型 ID	说明
adept/fuyu-8b	Fuyu 8B VLM
microsoft/kosmos-2	Kosmos 2 VLM
google/deplot	DePlot 图表理解
nvidia/neva-22b	Neva 22B VLM
nvidia/vila	VILA VLM
nvidia/nvclip	NVCLIP 视觉编码

可多模态但以视觉为主的模型（5 个）

模型 ID	说明
meta/llama-3.2-11b-vision-instruct	Llama 3.2 11B Vision
meta/llama-3.2-90b-vision-instruct	Llama 3.2 90B Vision
microsoft/phi-3-vision-128k-instruct	Phi 3 Vision
microsoft/phi-4-multimodal-instruct	Phi 4 Multimodal
nvidia/nemotron-nano-12b-v2-vl	Nemotron Nano 12B VL

模型 ID	说明
nvidia/llama-3.1-nemotron-nano-vl-8b-v1	Nemotron Nano VL 8B
nvidia/cosmos-reason2-8b	Cosmos Reason2 8B

专业/领域模型（7 个）

模型 ID	说明
bigcode/starcoder2-15b	StarCoder2 15B (代码生成)
deepseek-ai/deepseek-coder-6.7b-instruct	DeepSeek Coder 6.7B
google/codegemma-7b	CodeGemma 7B
google/codegemma-1.1-7b	CodeGemma 1.1 7B
nvidia/riva-translate-4b-instruct	Riva Translate 4B
nvidia/riva-translate-4b-instruct-v1.1	Riva Translate 4B v1.1
nvidia/llama3-chatqa-1.5-70b	ChatQA 1.5 70B

非 Instruct 基座模型（2 个）

模型 ID	说明
google/gemma-2b	Gemma 2B (基座，非 instruct)
google/recurrentgemma-2b	RecurrentGemma 2B (基座)

奖励/评分模型（1 个）

模型 ID	说明
nvidia/nemotron-4-340b-reward	Nemotron 4 Reward

检测/分类模型（2 个）

模型 ID	说明
nvidia/ai-synthetic-video-detector	AI 合成视频检测
nvidia/gliner-pii	GLiNER PII 检测

领域微调模型（3 个）

模型 ID	说明
writer/palmyra-fin-70b-32k	Palmyra Fin 金融
writer/palmyra-med-70b	Palmyra Med 医疗

模型 ID	说明
writer/palmyra-med-70b-32k	Palmyra Med 医疗 32K

科研专用（1 个）

模型 ID	说明
nvidia/ising-calibration-1-35b-a3b	Ising 校准模型

Nemotron Nano Omni Reasoning（1 个）

模型 ID	说明
nvidia/nemotron-3-nano-omni-30b-a3b-reasoning	Nemotron 3 Nano Omni Reasoning

三、使用方式

```
# 切换模型运行仿真实验
python pentest_agent_poison_sim.py \
  --scenario Labyrinth_Linguist \
  --experiments all \
  --model "deepseek-ai/deepseek-v4-pro"

# 多个模型对比
python pentest_agent_poison_sim.py --model "meta/llama-4-maverick-17b-128e-instruct" ...
python pentest_agent_poison_sim.py --model "qwen/qwen3.5-397b-a17b" ...
```

注意：部分大模型（如 `mistral-large-3-675b`、`nemotron-ultra-253b`）推理速度较慢、费用较高，大规模实验前建议先单轮验证。