

主流大语言模型（LLM）概览

2026年5月 · 学习笔记

一、国际模型

1. OpenAI — GPT 系列

模型	参数规模	特点
GPT-4o	~1.8T（估计）	多模态（文本+图片+语音），速度快，性价比高
GPT-4.1	~1.8T（估计）	最新旗舰，代码与指令遵循能力增强，支持 1M 上下文
o4-mini	未公开	推理模型（Chain-of-Thought），数学/逻辑/编程极强

- 公司：OpenAI（美国）
- 定位：全球标杆，生态最成熟（ChatGPT、API、GPTs）
- 安全对齐：极严，遇到攻击性任务会拒答

2. Anthropic — Claude 系列

模型	参数规模	特点
Claude Opus 4.7	未公开（估计 >1T）	旗舰，复杂推理+长上下文
Claude Sonnet 4.6	未公开	性价比之选，编码能力强
Claude Haiku 4.5	未公开	轻量快速，适合简单任务

- 公司：Anthropic（美国）
- 定位：安全优先，Constitutional AI
- 优势：200K 上下文窗口，代码生成质量高，安全对齐最严（蜜罐测试中直接拒答）

3. Google — Gemini 系列

模型	参数规模	特点
Gemini 2.5 Pro	未公开	推理能力强，原生多模态，1M 上下文
Gemini 2.5 Flash	未公开	轻量高速，性价比高

- 公司：Google DeepMind（美国）

- **定位：**多模态原生，与 Google 生态深度整合
- **优势：**超长上下文（1M token），搜索+AI 混合能力

4. Meta — Llama 系列（开源）

模型	参数规模	特点
Llama 4 Maverick	17B MoE	开源，128K 上下文
Llama 4 Behemoth	288B MoE	开源旗舰（待发布），教师模型

- **公司：**Meta（美国）
- **定位：**开源生态领导者，社区生态最活跃
- **优势：**免费可商用，支持本地部署，衍生模型极多

5. Mistral AI（法国）

模型	参数规模	特点
Mistral Large 3	675B	欧洲最强，多语言（法语/英语/中文等）

- **公司：**Mistral AI（法国）
- **定位：**欧洲 AI 标杆，开源+闭源双线
- **优势：**多语言能力突出，对非英语任务友好

二、中国模型

6. 阿里 — Qwen（通义千问）

模型	参数规模	特点
Qwen3.5-397B	397B MoE	阿里最新旗舰，中英双语极强

- **公司：**阿里巴巴
- **定位：**国内开源标杆，HuggingFace 下载量最高
- **优势：**中文能力顶级，开源生态好（Qwen-Coder 编程版很强）

7. DeepSeek（深度求索）

模型	参数规模	特点
DeepSeek V4 Pro	未公开（MoE）	推理能力强，训练成本极低
DeepSeek R1	未公开（MoE）	推理模型（类 o1），数学/编程顶级

- **公司：**深度求索（中国杭州）

- **定位：**高性价比，技术路线创新（MLA 注意力、MoE）
- **优势：**训练成本远低于同行，开源，API 价格极低

8. MiniMax

模型	参数规模	特点
MiniMax-M2.7	未公开（MoE）	多模态能力强，语音合成领先

- **公司：**MiniMax（中国上海）
- **定位：**多模态 + 语音，C 端产品（海螺 AI）
- **优势：**语音/视频生成领先，文本能力均衡

9. Moonshot AI — Kimi

模型	参数规模	特点
Kimi K2.6	未公开（MoE）	超长上下文，中文理解好

- **公司：**月之暗面（中国北京）
- **定位：**长上下文专家，C 端产品（Kimi 助手）
- **优势：**上下文窗口长，中文长文档处理强，学术场景友好

三、模型对比速查

维度	GPT-4o	Claude	Gemini	Qwen	DeepSeek	Mistral
中文能力	★★★★☆	★★★★☆	★★★★☆	★★★★★	★★★★★	★★★★☆
代码能力	★★★★★	★★★★★	★★★★☆	★★★★☆	★★★★☆	★★★★☆
安全对齐	严	最严	严	中等	中等	中等
开源	否	否	否	是	是	部分
API 成本	中	中	低	低	极低	中

四、与本研究的关联

本项目评测 LLM 作为渗透测试 agent 时，对 Unicode 字符扰动的鲁棒性差异：

- **安全对齐严格的模型**（Claude、GPT-4o）可能直接拒答攻击任务，反而提高防御效果
- **对齐宽松的模型**（Qwen、Mistral）更容易被诱导，但也更容易受字符扰动影响
- **同形字干扰**（homoglyph）对不同模型的干扰程度差异大——Qwen 对希腊字母替换不敏感，MiniMax 敏感
- **RLO 方向控制字符**效果最强，几乎所有模型都被干扰